

تمرین نظری سری اول

(۱) الف) سافت مکس امتیازات خود بی مدل را به احتمالات تبدیل می‌کند که مجموع آن‌ها ۱ است. پس از آنجا که در کلاسی بندی هدف پیش‌بینی احتمال هر کلاسی است این تابع مناسب می‌باشد.

(۲) ب) واریانس بالا یعنی مدل به نمونه‌های داده‌های آموزشی حساس است است که باعث می‌شود مدل لوفا کند. از روش‌های مرسوم برای کاهش واریانس می‌توان به Regularization اشاره کرد.

(۳) ج) رگرسیون Ridge وزن‌ها را بین ویژگی‌ها توزیع می‌کند در حالی که رگرسیون Lasso ممکن است بعضی ویژگی‌ها وزن صفر اختصاص دهد و آن‌ها را حذف کند که در صورت همبستگی ویژگی‌ها به هم ایده آل نیست.

(۴) د) رگولاریزیشن L2 یا همان رگرسیون Ridge با کاهش وزن‌های بزرگ از اورفیت جلوگیری می‌کند. اما اندکی به بایاسی مدل می‌افزاید که نت به مدل رگولاریز شده روی داده‌های آموزشی دقت کمتر به دست می‌آورد. ولی generalization مدل بالا رفته یعنی روی داده‌های دیده نشده دقت بهتری دارد که می‌دهد که مطلوب هم همین است.

(۵) ه) الف)

$$y = W^T x = w_1 x_1 + \dots + w_L x_L = x^T W$$

$$\rightarrow x y = x x^T W \xrightarrow[\text{3th row}]{\text{only feature } j} x_j y_j = x_j x_j^T w_j$$

$$\rightarrow w_j = \frac{x_j y_j}{x_j x_j^T}$$

(۶) ب) اگر دو ویژگی x_k و x_j مستقل باشند داریم:

$$x_j x_k^T = 0 \quad (j \neq k)$$

$$W = (X X^T)^{-1} X y = \begin{bmatrix} \frac{1}{x_1 x_1^T} & 0 & \dots & 0 \\ 0 & \frac{1}{x_2 x_2^T} & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & \dots & 0 & \frac{1}{x_L x_L^T} \end{bmatrix} X y$$

$$\Rightarrow w_j = \frac{x_j y_j}{x_j x_j^T}$$

(۱)

(5) (4)

$$y = W^T \kappa + w_0 \rightarrow W = (\kappa \kappa^T)^{-1} \kappa^T (y - w_0) \rightarrow w_j = \frac{\kappa^T (y - w_0)}{\kappa \kappa^T}$$

$$\kappa_{\text{new}} = \begin{bmatrix} 1 & \kappa_{11} & \kappa_{12} & \dots & \kappa_{1L} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & \kappa_{N1} & \dots & \dots & \kappa_{NL} \end{bmatrix}, W_{\text{new}} = \begin{bmatrix} w_0 \\ w_1 \\ \vdots \\ w_L \end{bmatrix}$$

$$W_{\text{new}} = (\kappa_{\text{new}} \kappa_{\text{new}}^T)^{-1} \kappa_{\text{new}}^T y_{\text{new}}$$

$$E[y] = \frac{1}{N} \sum_{i=1}^N y_i$$

$$E[\hat{y}] = \frac{1}{N} \sum_{i=1}^N (W^T \kappa + w_0) = W^T E[\kappa] + w_0$$

$$\rightarrow w_0 = E[\hat{y}] - W^T E[\kappa]$$

②


$$x_2 \leq x_1 - 2 \rightarrow x_2 - x_1 \leq -2$$

$$-1 \leq x_2 \leq 1$$

$$x_2 \leq -x_1 + 2 \rightarrow x_2 + x_1 \leq 2 \rightarrow -2 \leq x_1 + x_2 \leq 2$$

$$x_2 \geq -x_1 - 2 \rightarrow x_2 + x_1 \geq -2$$

$$x_2 \geq x_1 + 2 \rightarrow x_2 - x_1 \geq 2$$



$$i=k: \frac{\partial \hat{y}_i}{\partial z_i} = \frac{\partial}{\partial z_i} \left(\frac{e^{z_i}}{\sum e^{z_j}} \right) = \frac{(e^{z_i} \cdot \sum e^{z_j}) - (e^{z_i} \cdot e^{z_i})}{(\sum e^{z_j})^2} \quad (4) \text{ ان}$$

$$= \frac{e^{z_i} (\sum e^{z_j} - e^{z_i})}{(\sum e^{z_j})^2} = \hat{y}_i (1 - \hat{y}_i)$$

$$i \neq k: \frac{\partial \hat{y}_i}{\partial z_k} = \frac{\partial}{\partial z_k} \left(\frac{e^{z_i}}{\sum e^{z_j}} \right) = \frac{-e^{z_i} e^{z_k}}{(\sum e^{z_j})^2} = -\hat{y}_i \hat{y}_k$$

$$\frac{\partial L}{\partial z_i} = \sum_{j=1}^n \frac{\partial L}{\partial \hat{y}_j} \cdot \frac{\partial \hat{y}_j}{\partial z_i}$$

$$\frac{\partial L}{\partial \hat{y}_j} = \frac{\partial}{\partial \hat{y}_j} \left(-\sum_{j=1}^n y_j \log(\hat{y}_j) \right) = -\frac{y_j}{\hat{y}_j}$$

$$\xRightarrow{\text{ان}} \frac{\partial L}{\partial z_i} = -\frac{y_i}{\hat{y}_i} \cdot \frac{\partial \hat{y}_i}{\partial z_i} - \sum_{j \neq i} \frac{y_j}{\hat{y}_j} \cdot \frac{\partial \hat{y}_j}{\partial z_i}$$

$$= -y_i (1 - \hat{y}_i) + \sum_{j \neq i} y_j \hat{y}_i = \hat{y}_i \sum_{j=1}^n y_j - \hat{y}_i y_i$$

$$\sum_{j=1}^n y_j = 1 \rightarrow \frac{\partial L}{\partial z_i} = \hat{y}_i - y_i$$

(4)

$$\hat{\beta}^{LS} = (X^T X)^{-1} X^T y$$

$$\text{Var}(\hat{\beta}^{LS}) = \sigma^2 (X^T X)^{-1}$$

$$\hat{\beta}^{Ridge} = (X^T X + \lambda I)^{-1} X^T y$$

$$\text{Var}(\hat{\beta}^{Ridge}(\lambda)) = \sigma^2 (X^T X + \lambda I)^{-1} X^T X (X^T X + \lambda I)^{-1}$$

λI باعث اضافی eigen value σ^2 ہاں $X^T X$ میں سٹور ہیں λ inverse کو کم کرتے ہیں۔
 eigen value کم ہوتے ہیں: $(X^T X + \lambda I)^{-1} \leq (X^T X)^{-1}$

$$\rightarrow \begin{cases} \lambda = 0 & \text{Var}(\hat{\beta}^{Ridge}) = \text{Var}(\hat{\beta}^{LS}) \\ \lambda > 0 & \text{Var}(\hat{\beta}^{Ridge}) < \text{Var}(\hat{\beta}^{LS}) \end{cases}$$

$$\text{tr}(\text{Var}[\hat{Y}(\lambda)]) = \sigma^2 \sum_{j=1}^p (D_x)_{jj}^2 ((D_x)_{jj}^2 + \lambda)^{-2}$$

$$X^T X = Q D_x Q^T$$

$$\text{Var}[\hat{Y}(\lambda)] = \underbrace{X (X^T X + \lambda I)^{-1}}_{Q D_x Q^T} \underbrace{\text{Var}(y)}_{\sigma^2} (X^T X + \lambda I)^{-1} X^T$$

$$= \sigma^2 Q (D_x + \lambda I)^{-1} D_x (D_x + \lambda I)^{-1} Q^T$$

$$\rightarrow \sigma^2 \sum_{j=1}^p (D_x)_{jj}^4 ((D_x)_{jj}^2 + \lambda)^{-2}$$

(5)