

الف) میانگین هر ویژگی را به دست می آوریم:

$$\text{mean } w_1 = \frac{\begin{pmatrix} 4 \\ 1 \end{pmatrix} + \begin{pmatrix} 1 \\ 0 \end{pmatrix}}{2} = \begin{bmatrix} 2.5 \\ 0.5 \end{bmatrix}$$

$$\text{mean } w_2 = \frac{\begin{pmatrix} 2 \\ 5 \end{pmatrix} + \begin{pmatrix} 3 \\ 4 \end{pmatrix}}{2} = \begin{bmatrix} 2.5 \\ 4.5 \end{bmatrix}$$

ماتریس کوواریانس:

$$\Sigma_{w_1} = \frac{1}{2} \left[\begin{bmatrix} 4-2.5 \\ 1-0.5 \end{bmatrix} (4-2.5 \ 1-0.5) + \begin{bmatrix} 1-2.5 \\ 0-0.5 \end{bmatrix} (1-2.5 \ 0-0.5) \right]$$

$$\Sigma_{w_1} = \begin{bmatrix} 2.25 & 0.75 \\ 0.75 & 0.25 \end{bmatrix}$$

$$\Sigma_{w_2} = \frac{1}{2} \left[\begin{bmatrix} -0.5 \\ 0.5 \end{bmatrix} (-0.5 \ 0.5) + \begin{bmatrix} 0.5 \\ -0.5 \end{bmatrix} (0.5 \ -0.5) \right]$$

$$\Sigma_{w_2} = \begin{bmatrix} 0.25 & -0.25 \\ -0.25 & 0.25 \end{bmatrix}$$

ماتریس مقادیر ویژه:

$$\det(\Sigma_{w_1} - \lambda I) = 0$$

$$\rightarrow (2.25 - \lambda)(0.25 - \lambda) - (0.75)^2 = 0 \rightarrow \begin{cases} \lambda = 0 \\ \lambda = 2.5 \end{cases} \checkmark$$

$$\begin{bmatrix} 2.25 - 2.5 & 0.75 \\ 0.75 & 0.25 - 2.5 \end{bmatrix} \underbrace{\begin{bmatrix} x_1 \\ y_1 \end{bmatrix}}_{v_1} = 0 \rightarrow v_1 = \begin{bmatrix} 3 \\ 1 \end{bmatrix} \xrightarrow{\text{norm}} \frac{1}{\sqrt{10}} \begin{bmatrix} 3 \\ 1 \end{bmatrix}$$

$$\det(\Sigma_{w_2} - \lambda I) = 0$$

$$\rightarrow \begin{cases} \lambda = 0 \\ \lambda = 0.5 \end{cases} \checkmark \rightarrow \begin{bmatrix} -0.25 & -0.25 \\ -0.25 & -0.25 \end{bmatrix} \underbrace{\begin{bmatrix} x_2 \\ y_2 \end{bmatrix}}_{v_2} = 0 \rightarrow v_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix} \xrightarrow{\text{norm}} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

$$w_1: \begin{cases} \frac{1}{\sqrt{10}} \begin{bmatrix} 3 & 1 \end{bmatrix} \begin{bmatrix} 4 \\ 1 \end{bmatrix} = \frac{13}{\sqrt{10}} \\ \frac{1}{\sqrt{10}} \begin{bmatrix} 3 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \frac{3}{\sqrt{10}} \end{cases}$$

$$w_2: \begin{cases} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & -1 \end{bmatrix} \begin{bmatrix} 2 \\ 5 \end{bmatrix} = \frac{-3}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & -1 \end{bmatrix} \begin{bmatrix} 3 \\ 4 \end{bmatrix} = \frac{-1}{\sqrt{2}} \end{cases}$$

بردار عمود بر بردارهای دیگر :

$$v_1' = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \quad v_1 = \begin{bmatrix} 3/\sqrt{10} \\ 1/\sqrt{10} \end{bmatrix}$$

$$v_1' \perp v_1 \rightarrow \frac{3}{\sqrt{10}} x_1 + \frac{x_2}{\sqrt{10}} = 0 \rightarrow \begin{cases} x_1 = 1 \\ x_2 = -3 \end{cases} \rightarrow v_1' = \begin{bmatrix} 1 \\ -3 \end{bmatrix}$$

$$v_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix} \rightarrow v_2' = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

(۲) ان (Bias ($f_i(x)$) = $\mathbb{E}(f_i(x)) - f(x) = \mu - f(x)$)

$$\text{Bias}(f_{\text{ensemble}}(x)) = \mathbb{E}(f_i(x)) - f(x) = \frac{\mu \cdot m}{m} - f(x) = \mu - f(x)$$

با بایس تغییر نمی کند

$$\text{Var}(f_i(x)) = \sigma^2 \rightarrow \text{Var}(f_{\text{ensemble}}(x)) = \text{Var}\left(\frac{1}{m} \sum_{i=1}^m f_i(x)\right)$$

$$= \frac{1}{m^2} \sum_{i=1}^m \text{Var}(f_i(x)) = \frac{1}{m^2} \cdot m \sigma^2 = \frac{\sigma^2}{m} \rightarrow \text{واریانس کاهش می یابد!}$$

(ب) دایره مدل با بایس تغییر نمی دهد

$$\text{Var}(f_{\text{ensemble}}(x)) = \frac{1}{m^2} \text{Var}\left(\sum_{i=1}^m f_i(x)\right)$$

$$= \frac{1}{m^2} \left[\sum_{i=1}^m \text{Var}(f_i(x)) + \sum_{i \neq j} \text{Cov}(f_i(x), f_j(x)) \right]$$

$$= \frac{1}{m^2} [m \sigma^2 + m(m-1) \rho \sigma^2] = \frac{\sigma^2}{m} + \frac{(m-1)}{m} \sigma^2 \rho$$

اگر $\rho = 1$ باشد با افزایش تعداد واریانس تغییر نمی کند
 Var($f_{\text{ensemble}}(x)$) = σ^2
 پس هر چه m کوچکتر باشد تأثیر ensemble learning بیشتر است.

(۵) در AdaBoost نیازی به متنی پذیر بودن مدل های ضعیف نیست زیرا بر

اساسی تعدادی وزن مدل ها تعیین می شود بلکه بر اساس کارایی آن ها تعیین می شود.

به طوریکه به مدل ها با تعداد misclassification بیشتر، داده ها با وزن بزرگتری اختصاص داده می شود.

در Boosting از نظر محاسباتی گران تر است. زیرا الگوریتم های Boosting به صورت sequential


عمل می کنند درحالی که الگوریتم های Bagging مولزی پردازشی می کنند و وابستگی بین مدل ها وجود ندارد.

$$\text{error} = \frac{\# \text{misclassified}}{\# \text{total}} = \frac{2}{7} = 28.5\% \quad K=6 \quad (\text{ب) الف})$$

(ب) برای K های کوچک مدل به الگوهای جزئی و غیر مجموعی توجه می کند و نمی تواند به درستی بر روی داده های جدید عمل کند درستی داده ها بالاست.

برای K های خیلی بزرگ، مدل الگوهای محلی را در نظر نمی گیرد و تنها توانسته تفاوت های بین کلاس ها را به درستی تشخیص دهد.

$$\text{error} = 29\% \quad K=5 \quad (\text{ج}) \quad (\text{که در فایل zip})$$



$$\frac{\partial L}{\partial \mu_j} = 0 \rightarrow \sum_{i=1}^k \sum_{x_i \in S_j} 2 \|x_i - \mu_j\| = 0$$

(ع) اندام

$$\rightarrow \mu_j = \frac{\sum_{x_i \in S_j} x_i}{\|S_j\|} \rightarrow \text{میانگین هر خوشه}$$

ب) بله با توجه به مقداردهی های اولیه صارت Kmeans پاسخ های متفاوتی می تواند تولید کند. و بله Kmeans همواره همگرا می شود و بی لزوم جواب درست را پیدا نمی کند.

ج) اگر به فرض x به صورت x خوشه آن را انتخاب کند ممکن است در بین خوشه ها تابع با شود و این حرکت نوسانی باعث می شود همگرا شدن همگرا می شود.

$$f_u(x) = \arg \min_{v \in V} \|x - v\|^2$$

$$\Rightarrow f_u(x) = (x \cdot u)u$$

$$V = \{au; a \in \mathbb{R}\}$$

$$\frac{1}{m} \sum_{i=1}^m \|x^{(i)} - f_u(x^{(i)})\|^2 = \frac{1}{m} \sum_{i=1}^m \|x^{(i)} - (x^{(i)} \cdot u)u\|^2$$

$$\Rightarrow \|x^{(i)} - (x^{(i)} \cdot u)u\|^2 = \|x^{(i)}\|^2 - 2(x^{(i)} \cdot u)^2 + (x^{(i)} \cdot u)^2 \|u\|^2$$

$$\|u\|=1 \Rightarrow \|x^{(i)}\|^2 - (x^{(i)} \cdot u)^2$$

$$\Rightarrow \frac{1}{m} \sum_{i=1}^m \|x^{(i)}\|^2 - (x^{(i)} \cdot u)^2 \xrightarrow{\|x^{(i)}\|^2 \text{ ثابت}} \frac{1}{m} \sum_{i=1}^m (x^{(i)} \cdot u)^2 = \text{Var}(x)$$

$$\arg \min_{u: u^T u = 1} \frac{1}{m} \sum_{i=1}^m \|x^{(i)} - f_u(x^{(i)})\|^2 = \arg \max_{u: u^T u = 1} \frac{1}{m} \sum_{i=1}^m (x^{(i)} \cdot u)^2$$

u باید طوری انتخاب شود که واریانس را بیشینه کند که همان اولین مولفه اساسی است.