

$$\begin{cases} W_I = \frac{W - K}{1} + 1 \\ H_I = \frac{H - K}{1} + 1 \\ P_I = F \end{cases}$$

1 (الف) با فرض $stride=1$ و تعداد فیلتر F

تعداد وزن ها: $F \times (D \times K \times K)$
تعداد اتصالات: $(W_I \times H_I) \times F \times (D \times K \times K)$

برای لایه مترانم (بته) اباید تصویر به صورت یک بردار تک بعدی تبدیل بشود که طول آن $W \times H \times D$ است پس تعداد وزن ها: $W \times H \times D \times F$ که همان تعداد اتصالات نیز هست

همانطور که مشاهده می شود تعداد وزن ها در شبکه پیچیده و پیچیده کتر از تعداد وزن ها در شبکه مترانم است بنابراین برای آموزش شبکه مترانم به تعداد داده بسیار بیشتری نیاز دارد (برای جلوگیری از بیش برازش).
در شبکه های مترانم:

$$x = W u + b \xrightarrow{BN} \hat{x} = \frac{x - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}} \xrightarrow{shift \& scale} y = \gamma \hat{x} + \beta$$

ماتریس وزن ها بردار بایاس بردار بایاس

در این شبکه نرمال سازی به هر نورون مستقل از بایاس اعمال می شود.
در شبکه های کانولوشنی:

$$x = W * u + b \xrightarrow{BN} \hat{x}_{i,j} = \frac{x_{i,j} - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}} \xrightarrow{shift \& scale} y_{i,j} = \gamma \hat{x}_{i,j} + \beta$$

Kernel جمع درونی

در این شبکه نرمال سازی به هر نورون feature map اعمال می شود.

در صورت عدم استفاده از BN نبود بایاس ممکن است شبکه را دچار مشکل کند زیرا بایاس با انتقال داده های خروجی باعث یادگیری بهتر داده ها می شود. در صورت استفاده از BN نبود بایاس تأثیری در شبکه ندارد زیرا BN با shift & scale همان کار بایاس را انجام می دهد.
به دلیل BN ضرب کردن وزن ها در γ تأثیرش ندارد زیرا در نهایت BN اثرش را خنثی می کند.
به وزن ها ضرب α در ورودی تأثیری در عملکرد شبکه نخواهد داشت.

در پردازش تقویر پزشکی، به دلیل رزولوشن بالای آن‌ها و به تبع آن حجم فضای بالای حافظه، محولاً اندازه batch ها کوچکتر انتخاب می‌شود. batch با سایز کوچک محولاً باعث ناپایداری و نوسان نویزی می‌شوند. راه دل Group Normalization؛ نرمال سازی را در گروه های تقسیم شده توسط کانال ها انجام می‌شود.

(ج)

$$1st\ layer: 256 \times 256 \rightarrow 128 \times 128$$

$$2nd\ layer: 128 \times 128 \rightarrow 64 \times 64$$

$$3rd\ layer: 64 \times 64 \rightarrow 32 \times 32$$

$$4th\ layer: 32 \times 32 \rightarrow 16 \times 16$$

$$5th\ layer: 16 \times 16 \rightarrow 8 \times 8 \rightarrow 64\ pixels$$

$$تعداد پارامترها = 3 \times 3 \times 64 \times 128 + 128 = 73856$$

(د) Up-Convolutional این روش با بازسازی یک تصویر از ویژگی های استخراج شده استی معقد دارد

نشان دهنده در هر بازسازی از ویژگی ها چه اطلاعاتی حفظ می‌شود. این روش ترکیبی از Convolution و Upsampling است که نشان می‌دهد در لایه کانولوشن اول ویژگی های سطح بالایی مانند به یادمانست ها

در لایه های میان مانند لایه کانولوشن سوم ویژگی ها و الگوهای محلی دریافت می‌شود مانند شکل و نبشی

های مختلف انجام. در لایه های بالاتر مانند FC7 و FC8 هر ویژگی ها سطح بالا متکثر است و این روش با بازسازی و حفظ رشت تصویر نشان می‌دهد که لایه های کانولوشن اطلاعات بسیار زیادی را ذخیره می‌کنند.

Deconvolutional این شبکه مجزای از تصویر را مشخص می‌کند که بهترین کائیرا در فعال سازی یک سری نورون ها یا ویژگی های خاص دارند. در واقع این شبکه عملیات معکوس CNN را محسوسی می‌کند:

1- Upsampling 2- Deconvolution 3- Filtering

یک گروه از نورون ها انتخاب می‌شود و فعال سازی استی توسط backpropagation منجر به معور سازی

فت های مرتبط با آن گروه نورون می‌شود.

در روش معرفی شده می‌توانند این را برای بررسی حجم سیه های کانولوشن با سته، Up convolutional در تقیم

آنجی شبکه در کل ورودی حفظ می‌کند و deconvolutional در تقیم پاره ای از نورون ها به تفسیر پذیری کمک می‌کند

$$\frac{\partial L}{\partial w_j} = \sum_i \frac{\partial L}{\partial z_i} \cdot \frac{\partial z_i}{\partial w_j}$$

$$z_i = \sum_{j=0}^{k-1} w_j x_{i+j} \rightarrow \frac{\partial z_i}{\partial w_j} = x_{i+j}$$

$$\Rightarrow \frac{\partial L}{\partial w_j} = \sum_i \frac{\partial L}{\partial z_i} \cdot x_{i+j} = \left(\frac{\partial L}{\partial z} * x \right)_j$$

$$P_{i,j,k}^{(3)} = \frac{1}{4} \sum_{n=0}^{\wedge} \sum_{h=0}^{\wedge} p_{z_{i+h}, z_{j+h}, k}, \quad \frac{\partial L}{\partial \rho^{(3)}} = \frac{\partial L}{\partial z} \quad (1) \underline{3}$$

$$\frac{\partial L}{\partial \rho_{p,q,k}^{(2)}} = \sum_{i,j} \frac{\partial L}{\partial \rho_{i,j,k}^{(3)}} \cdot \frac{\partial \rho_{i,j,k}^{(3)}}{\partial \rho_{p,q,k}^{(2)}} = \frac{1}{4} \sum_{i,j} \frac{\partial L}{\partial \rho_{i,j,k}^{(3)}} \quad (2)$$

$$\frac{\partial L}{\partial \rho_{i,j,k}^{(1)}} = \sum_{p,q,k} \frac{\partial L}{\partial \rho_{p,q,k}^{(2)}} \cdot \frac{\partial \rho_{p,q,k}^{(2)}}{\partial \rho_{i,j,k}^{(1)}} \Rightarrow \frac{\partial L}{\partial \rho_{i,j,k}^{(1)}} = \frac{1}{4} \sum_k \sum_{i,j} \frac{\partial L}{\partial z} \cdot w_{k,i}^{(2)}$$

$$\rho_{i,j,k}^{(2)} = \sum_{m,n,l} w_{m,n,l,k}^{(2)} \cdot \rho_{i+m, j+n, l}^{(1)}$$

(-)

$$\frac{\partial L}{\partial w_{1,1,k}^{(1)}} = \sum_{i,j} \frac{\partial L}{\partial \rho_{i,j,k}^{(1)}} \cdot \frac{\partial \rho_{i,j,k}^{(1)}}{\partial w_{1,1,k}^{(1)}} = \frac{1}{4} \sum_n \sum_{i,k} \frac{\partial L}{\partial z} \cdot x_{k,i}$$

(2)


$$\frac{\partial \rho^{(1)}}{\partial w^{(1)}} = x$$

$$\frac{\partial L}{\partial w^{(2)}} = \sum_{p^{(1)}} \frac{\partial L}{\partial \rho^{(2)}} \cdot \frac{\partial \rho^{(2)}}{\partial w^{(2)}} = \frac{1}{4} \sum_{m,n} \frac{\partial L}{\partial z} \cdot \rho_{c,m,r,i,h+j}^{(1)}$$

4/1/ DenseNet تمام لایه‌ها را به لایه‌های قبلی متصل می‌کند. این اتصال باعث یادگیری از تکرار (تایید)

ناپدید شونده می‌شود. این شبکه برای ترکیب ورودی‌ها از concatenation (استاده‌ها) که باعث می‌شود مدل فشرده و روند تکرار بیان بهینه شود که خطر overfitting را کاهش می‌دهد.

ResNet مشکل تکرار بیان ناپدید شونده را با اتصالات Residual حل می‌کند. این اتصالات به لایه‌ها اجازه می‌دهد تا ورودی خود را به لایه‌های محقق ترانسلمت کنند. این عملیات از جمع خروجی لایه محقق ترانسلمت با ورودی لایه‌های قبلی انجام می‌شود و در صورت ضرورت تکرار بیان اتصال Residual با جمع کردن تکرار بیان ورودی صاف می‌شود و ضرورت تکرار بیان حل می‌شود.



همان‌طور که گفته شد تفاوت اصلی دو مدل نحوه اتصالات و نحوه ترکیب کردن آن‌هاست (جمع، concatenation)

به دلیل وجود اتصالات متغیر از loss function به تمام لایه‌ها، به علاوه ورودی اصلی، باعث می‌شود تا تکرار بیان به راحتی در شبکه جریان داشته باشد بدون آن‌که ناپدید شود.
مزایای حسابی DenseNet:

- 1- عدم نیاز به یادگیری مجدد تعداد زیادی ویژگی به دلیل استفاده مجدد از خروجی لایه‌ها اول
- 2- به دلیل یادگیری تجزیه این مدل، DenseNet نیاز به تعداد زیادی فیلتر ندارد. (کمتر از دیگر مدل‌ها)
- 3- اتصالات مترادف این مدل نوعی Regularization محسوب می‌شود که overfitting را کاهش می‌دهد.

$$k=24$$

$$\text{Total layer} = 32 + 3k = 104$$

$$\text{تعداد عملیات} = 28 \times 28 \times 32 \times 5 \times 5 \times 192$$

$$\text{شماره بدون 1x1 Conv} = 120422400$$

$$\text{تعداد عملیات با 1x1 Conv} = 28 \times 28 \times 16 \times 1 \times 1 \times 192 + 28 \times 28 \times 32 \times 5 \times 5 \times 76$$

$$= 12443648$$

$$\text{درصد کاهش عملیات} = \frac{120422400 - 12443648}{120422400} \approx 89.7\%$$

ترکیب فیلترهای مختلف به مدل اجازه می‌دهد تا الگوهای محلی و وسیع‌تری را بیاموزد (یا دیگر).

میدان
64 Filters (1x1)
padding=0
stride=1

$$\left\{ \begin{array}{l} \text{خردی} = 28 \times 28 \times 64 \\ \text{تعداد عملیات} = 28 \times 28 \times 64 \times (1 \times 1 \times 192) \\ = 9830400 \end{array} \right.$$

میدان دوم
96 (1x1) + 128 (3x3)
padding=0 padding=1
stride=1 stride=1

$$\left\{ \begin{array}{l} \text{خردی} = 28 \times 28 \times 128 \\ \text{تعداد عملیات} = 28 \times 28 \times 96 \times 192 + 28 \times 28 \times 128 \times 3 \times 3 \times 76 \\ = 42004224 \end{array} \right.$$

میدان سوم
16 (1x1) + 32 (5x5)
padding=0 padding=2
stride=1 stride=1

$$\left\{ \begin{array}{l} \text{خردی} = 28 \times 28 \times 32 \\ \text{تعداد عملیات} = 28 \times 28 \times 16 \times 192 + 28 \times 28 \times 32 \times 5 \times 5 \times 76 \\ = 12779520 \end{array} \right.$$

میدان چهارم
Max pool (2x2)
p=1 p=0
s=1 s=1

$$\left\{ \begin{array}{l} \text{خردی} = 28 \times 28 \times 32 \\ \text{تعداد عملیات} = 0 + 28 \times 28 \times 32 \times 1 \times 1 \times 192 = 4715200 \end{array} \right.$$

67529344 = تعداد کل عملیات

بله این معماری به گزاردن تأیید شده مقام است زیرا :

1- **فیلتر** 1x1 مانند لایه bottleneck عمل میکنند که باعث کاهش ابعاد ویژگی‌های ورودی می‌شود و می‌تواند به تعداد ترانزستورها

2- **Auxiliary Classifier** های موجود در این معماری با افزودن دسایا های اضافه مانند می‌تواند برای گزاردن

عمل می‌کنند. باعث می‌شود لایه های اول به گزاردن قدرتی دریافت کنند.

3- وجود می‌تواند باعث می‌شود اگر گزاردن در می‌رسد تأیید شده در می‌رسد این اثر جریان می‌شود.

Auxiliary Classifier ها **Classifier** های هستند که در لایه های عمیق شبکه قرار دارند. این می‌تواند به با استفاده از ویژگی‌های استخراج شده از لایه های میانی به یک خروجی تولید می‌کنند. این می‌تواند به حفظ در زمان آموزش کار می‌کند در زمان Inference تأیید شده می‌شود.

محدودیت‌های این مدل :

1- پیچیدگی طراحی معماری

2- از نظر فضای حافظه سنگین

3- امکان هزینه اضافی در Auxiliary Classifier

4- عدم انعطاف پذیری در اندازه فیلترها

5- عدم وجود skip connection

(ج) تفاوت اصلی CNN معمولی با Deformable در sampling grid است. در CNNs کلاسیک اندازه sampling ثابت و معین است ولی در Deformable با استفاده از augmented می‌شود تا بتواند با ورودی خود تطبیق دهد. **learned offset** به صورت پویا و بر اساس نگاشت های قبلی تعیین می‌شود این باعث می‌شود که sampling grid غیر معین ولی انعطاف پذیر باشد.

نسبت های پیکچر Deformable به دلیل adaptive sampling در درون یابی دو بخشی می‌تواند در برابر تغییرات اندازه تصویر منعطف باشد.

offset از پارامترهای ویژگی‌های قبلی با تبدیل Convolution حساب می‌شود.

$D=1 \rightarrow \text{Effective field} = F \times F = 3 \times 3$ باقیہ شکل (الف)
 $D=2 \rightarrow \text{Effective field} = 5 \times 5$
 $D=3 \rightarrow \text{Effective field} = 7 \times 7$

General: $D \rightarrow (F-1) \times D + 1$

Input: $M \times N$

Output: $(M - ((F-1)D + 1) + 1) \times (N - ((F-1)D + 1) + 1)$

$= (M - FD + D) \times (N - FD + D)$

$K \otimes A = \begin{bmatrix} k_{11}A & \dots & k_{1F}A \\ \vdots & \ddots & \vdots \\ k_{F1}A & \dots & k_{FF}A \end{bmatrix}$

$D=2 \rightarrow \begin{bmatrix} k_{11} & 0 & k_{12} & \dots & 0 \\ 0 & 0 & 0 & \dots & 0 \\ k_{21} & 0 & k_{22} & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ k_{F1} & 0 & k_{F2} & \dots & 0 \end{bmatrix} \Rightarrow A = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}$

$\rightarrow A_{D \times D} = \begin{cases} a_{11} = 1 \\ a_{ij} = 0 \quad i \neq 1, j \neq 1 \end{cases} \rightarrow \text{last row should be dropped (All zeros)}$

Layer 1: $F_1 = w-1$ \rightarrow Receptive Field: $D_1(F_1-1)+1 = (d-1)(w-2)+1$ (2)
 $D_1 = d-1$

Layer 2: $F_2 = w$ \rightarrow Receptive Field: $d(w-1)+1 + R_1-1 = d(w-1)+1 + (d-1)(w-2)$
 $D_2 = d$

Layer 3: $F_2 = w+1$ \rightarrow Receptive Field: $(d+1)w+1 + R_2-1 = w(d+1)+d(w-1)+(d-1)(w-2)+1$
 $D_2 = d+1$

$= (3w-3)d + 3$

➤ **Mask convolution**: یک نوع از کانولوشنی که یک mask به کنترل اعمال مستودنا وزن های خاصی را میگذارد تا تأثیر برخی نودون های ورودی را از بین ببرد. کاربرد این کانولوشنی معمولاً در پردازش داده های sequential است. برای مثال mask convolution تضمین می کند که پیکسل فردی صرفاً به پیکسل های قبل و بعد (نه به پیکسل های بعدی) در پیش بینی سری زمانی نیز بر کار برد است. از محدودیت های این روش می توان به موارد زیر اشاره کرد:

1- **محدودیت ماه سختگیرانه**: ماسک ها ممکن است در برخی سناریوهای بسیار سختگیرانه عمل کنند به خصوص در مواردی که وابستگی ها رنج وسیعی دارند.

2- **گرادیان کم**: به دلیل masking جریان گرادیان کم می شود که فرایند بهینه سازی را دشوار می کند.

3- **کاهش Receptive Field**: عملیات masking باعث کاهش Receptive Field می شود.

با استفاده از کانولوشن گسترش یافته در mask convolution می توان محدودیت های بالا را کاهش داد. با گسترش Receptive field عملیات masking به صورت پهن تر و گسترده تر انجام می شود که باعث بهبود جریان گرادیان و کارایی مدل می شود.

4- **اثبات** با فرض بزرگترین متغیر (کسین برای w_k) داریم:

$$\left\| \sum_{k=1}^L w_k \right\| \leq (\sigma_{\max})^n, \quad n = L - i$$

از آنجا که σ_{\max} با بردن n به سمت بی نهایت به صفر میل می کند که با توجه به رابطه بازگشت در صورت سوال $\delta_i \rightarrow 0$ که باعث گرادیان نامیده می شود می شود.

$$\sigma_{\max} = 0.9, \quad L = 100$$

$$\delta_L = \epsilon \rightarrow |\delta_i| \leq \epsilon \cdot (0.9)^{L-i} \xrightarrow{i=0} |\delta_0| \leq \epsilon \cdot (0.9)^{100}$$

$$\rightarrow |\delta_0| \leq 2.6 \times 10^{-5} \times \epsilon$$

$$\text{Var}[w] = \frac{2}{n_l}$$

$$n_l = \text{input channels} \times \text{kernel size} = 3 \times 8 \times 8 = 192$$

$$\text{Var}[w] = \frac{2}{192} = 0.0104 \rightarrow \sigma = \sqrt{\text{Var}} = 0.102$$

$$\text{Normalization} \rightarrow \mu = 0 \rightarrow w_l \sim \mathcal{N}(0, (0.102)^2)$$

(ج) در Sigmoid برای داده‌های بزرگ یا بسیار کوچک به مقدارهای 1 و 0 अभिसر می‌شود که باعث به وجود آمدن گرادیان صفر می‌شود. تا جایی که ReLU در مقدار مثبت همواره گرادیان ثابت +1 را دارد و برای مقادیر منفی صفر می‌شود که لزوماً به گرادیان صفر منجر نمی‌شود زیرا همواره نودن‌های مثبت وجود دارند.

(د) مشکل نودن‌های مرده وقتی رخ می‌دهد که مقادیر نودن‌ها منفی باشند. خروجی ReLU برای نودن‌های منفی صفر است که باعث گرادیان صفر می‌شود. راه حل 1

$$1- \text{ReLU} : f(x) = \begin{cases} x & x > 0 \\ \alpha x & x \leq 0 \end{cases} \rightarrow f'(x) = \begin{cases} 1 & x > 0 \\ \alpha & x \leq 0 \end{cases}$$

مزايا: α یک پارامتر قابل یادگیری است، حل مشکل نودن‌های مرده

معایب: افزودن پارامتر، بالا رفتن پیچیدگی مدل و به نفع آن اثراتی نیز دارد *overfitting*

$$2- \text{Leaky ReLU} : f(x) = \begin{cases} x & x > 0 \\ \alpha x & x \leq 0 \end{cases} \rightarrow f'(x) = \begin{cases} 1 & x > 0 \\ \alpha & x \leq 0 \end{cases}$$

$\alpha = \text{a small constant}$

مزايا: عدم افزودن پارامتر، جلوگیری از مشکل نودن‌های مرده

معایب: α تعیین شده ممکن است بهینه نباشد، عدم انعطاف پذیری

$$3-ELU: f(x) = \begin{cases} x & x > 0 \\ \alpha(e^x - 1) & x \leq 0 \end{cases} \rightarrow f'(x) = \begin{cases} 1 & x > 0 \\ \alpha e^x & x \leq 0 \end{cases}$$

۴. یک هاپر یا راسر است که معمولاً به $\alpha=1$ تنظیم می‌شود.

مزایا: عدم وجود مشتق در نقطه صفر (Smooth) / بهبود جریان گرادیان، مرکزی شده به صفر
معایب: هزینه محاسباتی به دلیل e^x ، تنظیم هاپر یا راسر ۴ برای یادگیرنده

(۵)

$$y_{\text{black}} = F(x) + x$$

$$x_1 = F(x_0) + x_0$$

$$x_2 = f(x_1) + x_1 = F(F(x_0) + x_0) + F(x_0) + x_0$$

$$\frac{\partial x_2}{\partial x_1} = 1 + \frac{\partial F(x_1)}{\partial x_1} \xrightarrow{\frac{\partial F(x_1)}{\partial x_1} \rightarrow 0} \frac{\partial x_2}{\partial x_1} = 1 \neq 0$$

۵. به دلیل سه اضافه گرادیان صفری شود به طوری یادگیرنده ثابت کامل $H(x)$ هر بلوک صفری
ثابت اصلاحیه را یاد می‌گیرد $F(x) = H(x) - x$ که برای بین سازی بهتر است
در شبکه های نرمال:

$$x_1 = F(x_0)$$

$$x_2 = F(x_1)$$

$$\frac{\partial x_2}{\partial x_0} = \frac{\partial F(x_2)}{\partial x_1} \frac{\partial F(x_1)}{\partial x_0}$$

اگر یکی مشتق ها کوچک شود (به صفر میل کند) ثابت صفر شدن کل گرادیان و تأخیری آن می‌شود