

(الف)

از بزرگترین اول و آخر 4 جفت می‌دهد $\rightarrow window\ size=2$

*

$$34 = 2 \times 2 + 3 \times 2 + 4 \times 6 = \text{تعداد جفت‌های میانی}$$

2 جفت برای که اول و آخر 3 جفت برای که دوم و یکی مانده به آخر

$$34 \times 5 = 170$$

هر جفت می‌دهد 5 سید منفی تولید می‌کند پس داریم :

$$34 + 170 = 204$$

4 *

$$d_{head} = d_{model} / h \rightarrow w_q, w_k, w_v \in \mathbb{R}^{d_{model} \times d_{head}}$$

*

کاهش ابعاد از d_{model} به d_{head} باعث کاهش سر بار محاسباتی هنگام ضرب ماتریس ها می‌شود. از طرفی سازه سازی باعث افزایش صرف منابع شده و سر بار را افزایش می‌دهد.

(ب) * صحیح. غلط، با افزایش تعداد head ها ممکن است head های مشابه تولید کنند.

$$-\frac{\partial}{\partial v_{w_0}} \log \sum_{k \in V} \exp(u_{wt}^T v_k) = -\frac{\partial}{\partial v_{w_0}} (u_{wt}^T v_{w_0} - \log \sum_{k \in V} \exp(u_{wt}^T v_k))$$

$$= -\left(u_{wt} - \frac{\sum_k u_{wt} \exp(u_{wt}^T v_k)}{\sum_k \exp(u_{wt}^T v_k)}\right) = \sum_k u_{wt} P(w_k | w_{wt}) - u_{wt}$$

(ب) برای $c=1$ ، مدل بیشتر بر روی روابط و اتصالات محلی با بردار کوتاه متمرکز می‌گردد. این باعث می‌شود که مدل روابط دستوری بین کلمات را یاد بگیرد.

برای $c=100$ ، مدل بیشتر از کلمات درامت می‌شود که باعث می‌شود که مدل روابط معنایی بین کلمات را بهتر یاد بگیرد.

$c=5$ می‌تواند به معنای این دو حالت قبلی است

$$\text{Output} = \text{Softmax} \left(\frac{QK^T}{\sqrt{d}} \right) V$$

(الف)

$$\frac{QK^T}{\sqrt{d}} = \frac{1}{\sqrt{d}} X W_Q W_K^T X^T$$

برای اینکه به صورت یک FCN باشد باید $\frac{QK^T}{\sqrt{d}} = W X X^T$ پس داریم:

$$W X X^T = \frac{1}{\sqrt{d}} X W_Q W_K^T X^T \xrightarrow{M = \frac{1}{\sqrt{d}} W_Q W_K^T} W X X^T = X M X^T$$

$$W = f(M) \rightarrow W_{ij} = \sum_{k,l} M_{kl} \cdot g(X_i, X_j) \rightarrow \text{output} = \text{softmax}(W X X^T)$$

$$W_Q W_K^T \rightarrow D \times D \rightarrow D^2$$

$$W X X^T \rightarrow N \times N \rightarrow N^2 \rightarrow D^2 N^2$$

(ب)

$$A = \text{softmax}(QK^T)$$

(ج) بسیاری از عناصر ماتریس A به دلیل احتمال دور شدن کوک و مقدار نزدیک به صفر دارد که باعث می شود ماتریس

$$A_{ij} = \text{softmax}(Q_i K_j^T)$$

Sparse شود. همچنین اگر توکن ها دورن

های یکسان برای توکن های دیگر داشته باشند در این صورت آن ها نیز به هم وابسته

(د)

$$H_i = \text{Attention}(Q_i, K_i, V_i)$$

$$Q_i = X W_i^Q, K_i = X W_i^K, V_i = X W_i^V$$

$$Q_i = K_i = V_i = X \leftarrow W_i^Q = W_i^K = W_i^V, \text{ creating}$$

$$\text{softmax}\left(\frac{X X^T}{\sqrt{d}}\right) \rightarrow \text{redistribution of input}$$

$$\text{softmax}\left(\frac{X X^T}{\sqrt{d}}\right) X \rightarrow \text{rearranged input}$$

$$\text{Input} = (32, 2048, 768)$$

: Encoder - I (E)

$$V, K, Q = (32, 2048, 768)$$

$$\text{Multihead Attention output} : (32, 2048, 768)$$

$$\text{Feed Forward Layer 1} : (32, 2048, 384)$$

$$\text{Feed Forward Layer 2} : (32, 2048, 768)$$

$$\text{Input} : (32, 2048, 768)$$

: decoder

$$\text{Self Attention output} : (32, 2048, 768)$$

$$\text{Cross Attention output} : (32, 2048, 768)$$

$$\text{Feed forward layer 1} : (32, 2048, 384)$$

$$\text{Feed forward layer 2} : (32, 2048, 768)$$

$$\text{Token Embedding} : 30000 \times 768 = 23040000 \quad \text{: Encoder - Y}$$

$$\text{Self Attention} : 4 \times 768 \times 768 = 2357296$$

$$\times 8 \rightarrow 18874368$$

$$\text{Feed Forward} : \begin{cases} \text{Layer 1: } 768 \times 384 = 294912 \\ \text{Layer 2: } 768 \times 384 = 294912 \end{cases} + = 589824$$

$$\times 8 \rightarrow 4718592$$

$$\text{Layer Norm.} : 2 \times 768 \times 8 = 12288$$

$$\text{Total} = 46645248$$

$$12 \times 2357296 = 28311552 : \text{Self Attention} \quad \text{Encoder}$$

$$12 \times 2359296 = 28319552 : \text{Cross Attention}$$

$$\text{Feed Forward: } 12 \times 589824 = 7077888$$

$$\text{Layer Norm: } 2 \times 268 \times 12 = 98432$$

$$\text{Total} = 63717424$$

$$\text{"He is sleeping"} \rightarrow x_{\text{input}} = [\text{Token}_1, \text{Token}_2, \text{Token}_3] \quad \text{He is sleeping}$$

$$\text{embedding } (32, 2048, 768) \xrightarrow{\text{encoder}} \text{Context representation}$$

$$\text{Decoder input: } y_{\text{input}} (\text{نَرْسِیَ جَان}) = [\text{SOS}] \xrightarrow{\text{self}} \text{generate tokens}$$

$\xrightarrow{\text{cross}} \text{Best match for generating}$

$$\xrightarrow{^n} [\text{SOS}] \xrightarrow{\text{He}} [\text{SOS}] \xrightarrow{\text{is}} [\text{SOS}] \xrightarrow{\text{sleeping}} [\text{SOS}]$$

$$[\text{Eos}] \xrightarrow{^n} [\text{SOS}] \text{ اور تو اُبڑھ } [\text{Eos}]$$

(۷) یک دلیل بدیهی کاهش هزینه محاسباتی است. دلیل دیگر $Generalization$ بهتر است زیرا

در رابطه بین جملات معرّفه مختص به یک task یا موضوع خاص می‌شود. دلیل بعدی شواهد تجربی است که نشان داده مدل‌های مانند RoBERTa که از NSP استفاده نمی‌کنند از مدل BERT کارآمدتر اند.

ب) و نهادهای پردازش زبان طبیعی را به یک بردار مابطن ثابت می‌زنند، این بردار تعیین می‌کند که کلمات کلمات داخل جمله را نشان دهد. حراقت این تک بردار معنی یک جمله را به صورت غنّده ذخیره می‌کند.

که در task ها مانند sentiment analysis می‌تواند بسیار پیرا ربرد باشد.